생성형 AI 와 Vertex AI

- **파운데이션 모델(Foundation Model)** 대규모 데이터로 사전 학습한 범용 모델. 생성·요약·분류·질의응답 등 다양한 작업에 활용한다.
- **Vertex AI :** Google Cloud 의 통합 AI/ML 플랫폼. 모델 개발, 튜닝, 배포 및 운영을 지원한다.
- **Vertex AI Studio (Generative AI Studio) :** GUI 에서 프롬프트를 작성·시험하고 모델 설정 및 지원되는 튜닝 기능을 활용한다. Model Garden 은 모델 탐색, Workbench 는 노트북 개발 환경이다.
- **대표 활용 패턴 :** 요약(Summarization), 생성(Generation), 정보 추출(Extraction: 문서→JSON/표), 변환·번역(Transformation & Translation), 분류(Classification).

GCP 프로젝트 · IAM · 인증

- **프로젝트 ID** 프로젝트 생성 시 정하는 고유 문자열로, 생성 후 변경할 수 없다. 프로젝트 번호는 Google 이 자동 부여하는 별도 식별자다.
- **IAM 권한** 기본 역할(Owner/Editor/Viewer)은 권한 범위가 넓어 최소 권한 원칙상 가급적 지양한다. 서비스별 사전 정의된 역할이나 커스텀 역할을 우선 사용한다.
- **ADC (Application Default Credentials)** Python 라이브러리가 실행 환경의 Google 인증 정보를 자동 탐색해 API 를 호출하는 인증 방식. 로컬 개발에서는 보통 gcloud auth application-default login 을 사용한다.
- **리전 선택** us-central1 은 개발·PoC 에서 자주 선택되는 리전이지만 최신 모델의 지원 여부·할당량은 모델·리전별로 다르므로 확인이 필요하다. 서울은 asia-northeast3.

임베딩과 RAG 검색 구조

- **임베딩(Embedding)** 텍스트를 의미를 담은 숫자 벡터로 표현한다. 코사인 유사도는 두 벡터의 방향을 비교하는 대표적인 의미 유사성 척도다.
- **RAG (검색 증강 생성)** 문서를 색인(Indexing) → 관련 내용 검색(Retrieval) → 검색 결과를 포함해 프롬프트 구성 → LLM 답변 생성 순으로 동작한다.
- **청킹과 중첩** 긴 문서를 작은 청크로 분할하며 Chunk Overlap 은 앞 청크의 끝부분을 다음 청크에 겹쳐 넣어 문맥 단절을 줄인다.
- **RecursiveCharacterTextSplitter** 기본 구분자 우선순위는 단락(₩n₩n) → 줄바꿈(₩n) → 공백( ) → 문자 단위(빈 문자열)이다.
- **벡터 저장소** FAISS 는 벡터 검색 라이브러리, Chroma 는 로컬 사용도 가능한 벡터 DB. Vertex AI Vector Search 는 대규모 운영에 쓰는 관리형 벡터 검색 서비스다.
- **환각(Hallucination)** 모델이 근거가 부족하거나 없는 내용을 사실처럼 생성하는 현상. RAG 는 외부 근거를 보완하지만 환각을 완전히 없애지는 못한다.

프롬프트 설계와 모델 실행

- **Few-shot · CoT** Few-shot 은 입력·출력 예시 몇 개로 원하는 패턴을 보여준다. Chain-of-Thought(CoT)는 중간 추론 단계를 활용하도록 유도하는 기법으로, 파인튜닝과는 다르다.
- **Temperature** 낮을수록 출력의 무작위성이 줄고 일관성이 높아지며, 높을수록 표현이 다양해진다. 낮은 값이 사실 정확성을 보장하는 것은 아니다.
- **Function Calling** 모델이 도구/API 를 호출하도록 함수 이름과 인자를 구조화해 제안하는 방식. 실제 실행은 애플리케이션 또는 실행 환경이 담당한다.